
Classificação de Manganês na Folha da Mexerica, Orientado por Redes Neurais

ALVES, A; FAGUNDES, L.; FREITAS, V.; RODRIGUES, J.

Desenvolvimento de Software Multiplataforma

FATEC Registro

25 de maio de 2026

Agenda

- Pitch
- Problematização
- Objetivo
- Estado da Arte
- Ferramental
- Metodologia
- Apresentação prática
- Resultados e Discussões

Duração: 10 a 11 min.


Pitch

- **NitrusLeaf:** Cuidando da sua plantação!



Problematização

- Registro de alta incidência de greening (>60%) na citricultura paulista.
- Sintomas do greening são semelhantes a deficiências nutricionais, dificultando o diagnóstico.
- Essa confusão pode gerar perdas no manejo das lavouras.
- Pequenos produtores têm acesso limitado a ferramentas de diagnóstico.



Fonte: Fundecitrus, Araraquara, São Paulo 2025

Imagem: Percentual das laranjeiras com greening por setor e região

Objetivo

- **Objetivo geral:** Desenvolver o **NitrusLeaf**, para identificar deficiência nutricional de manganês ou cobre em folhas de mexerica com IA.
- **Objetivos específicos:**
 - Criar banco de imagens rotuladas.
 - Treinar e validar a CNN.
 - Desenvolver aplicativo móvel
- Resultados esperados e **entregas:** Aplicativo funcional e acessível, com modelo de IA validado e base de dados organizada.

Fonte: Autoria Própria




Imagem: Símbolo IA e mexerica

Estado da Arte

Abordagens Baseadas em Visão Computacional, Aprendizado de Máquina e Aprendizado Profundo para Identificação de Deficiências Nutricionais em Culturas

Título/Autores	Objetivo	Método	Resultados	Limitações	Gap
Computer Vision Based Machine Learning and Deep Learning Approaches for Identification of Nutrient Deficiency in Crops: A Survey - Sudhakar e Swarna Priya (2023)	Revisar técnicas de visão computacional para detectar deficiência nutricional em plantas	Survey de trabalhos com ML, DL, UAVs, IoT e sensoriamento remoto	CNNs, UAVs e IoT apresentaram bons resultados na identificação de deficiências	Dependência de grandes bases de dados e dificuldade em diferentes ambientes	Falta de sistemas em tempo real e foco limitado em micronutrientes

Estado da Arte

Detecção de Doenças e Deficiências Nutricionais em Plantas Baseada em Processamento de Imagens

Título/Autores	Objetivo	Método	Resultados	Limitações	Gap
Image Processing Based Detection of Diseases and Nutrient Deficiencies in Plants - Ghorai et al. (2021)	Revisar técnicas de processamento de imagens para detectar doenças e deficiências nutricionais em plantas	Survey sobre visão computacional, segmentação, extração de características e classificadores de ML	CNNs, SVM e imagens hiperespectrais apresentaram alta eficiência na detecção de doenças e deficiências	Sensível a iluminação, ruídos e variações ambientais durante captura das imagens	Necessidade de sistemas mais robustos, automáticos e em tempo real para uso em campo

Estado da Arte

Um Estudo Comparativo de Deep CNN Na Previsão e Classificação de Deficiências de Macronutrientes no Desenvolvimento de Plantas de Tomate

Título/Autores	Objetivo	Método	Resultados	Limitações	Gap
A Comparative Study of Deep CNN in Forecasting and Classifying the Macronutrient Deficiencies on Development of Tomato Plant - Tran et al. (2019)	Classificar e prever deficiências nutricionais em tomateiros utilizando Deep Learning	Uso de CNNs (Inception-ResNet v2 e Autoencoder) com imagens de folhas e frutos; aplicação de Ensemble Averaging	Acurácia de 87,27% com Inception-ResNet v2 e 91% utilizando ensemble learning	Dataset reduzido (571 imagens), foco apenas em tomateiros e condições controladas de estufa	Necessidade de validação em ambientes reais e adaptação para diferentes culturas agrícolas e micronutrientes

Ferramental

- **Linguagens:** Python
- **Frameworks e bibliotecas:** TensorFlow, Keras, React, Next.js e Node.js
- **Banco de dados:** MySQL hospedado no Supabase
- **Infraestrutura:** API de comunicação entre aplicativo e servidor
- **Ferramentas:** Figma, Git e VS Code
- **APIs e integrações:** Integração entre aplicativo móvel, API Node.js e modelo de IA


Fonte: Autoria Própria



Imagem: Logos das tecnologias utilizadas

Metodologia

Fluxograma dos principais processos implementados no projeto, evidenciando as tecnologias empregadas, tais como Inteligência Artificial (IA) e Banco de Dados.



Apresentação Prática

- **Demonstração** ao vivo do sistema
- Principais **funcionalidades** implementadas
- **Interface** e experiência do usuário
- Fluxos de **uso** e navegação
- Casos de uso e **cenários** práticos

Fonte: Autoria Própria



Imagem: Descrição da imagem

Resultados e Discussões

Resultados Técnicos da IA e Discussão:

- Acurácia de 95,97% no modelo treinado, eficiente mesmo com poucos dados.

Limitações e Escopo do Projeto:

- Baixo volume de dados, foco apenas na deficiência de manganês.

Trabalhos Futuros:

- Incluir deficiência de cobre no Escopo, tornar o sistema multiclasse e avaliação de arquiteturas pré-treinadas como ResNet e MobileNet.

Fonte: Autoria Própria

Desempenho do Classificador - Acurácia Final: 88.0%




Imagem: Desempenho do modelo de classificação das folhas de mexerica

Obrigado!

